

Deteksi Dini *Churn* Pelanggan *E-Commerce* Berbasis CRM di Indonesia Menggunakan Algoritma Random Forest

Alifa Putri Shahabiyah¹⁾, Zakirah Sabrina Putri Pasha²⁾, Aliya Faiza³⁾, Ali Ibrahim⁴⁾, Fathoni⁵⁾

^{1,2,3,4,5} Sistem Informasi, Fakultas Ilmu Komputer, Universitas Sriwijaya

Jl. Raya Palembang - Prabumulih, Km. 32, Indralaya, Ogan Ilir, Sumatera Selatan 30862, Indonesia

Email: ¹⁾09031282328116@student.unsri.ac.id, ²⁾09031182328021@student.unsri.ac.id,

³⁾09031182328001@student.unsri.ac.id, ⁴⁾aliibrahim@unsri.ac.id, ⁵⁾fathoni@unsri.ac.id

Abstrak

Fenomena *customer churn* merupakan tantangan krusial dalam ekosistem *e-commerce* kontemporer yang berimplikasi langsung pada profitabilitas dan stabilitas pangsa pasar perusahaan. Meskipun diskursus prediksi *churn* telah berkembang pesat, mayoritas pendekatan konvensional terpaku pada parameter transaksional teknis semata, sehingga mengabaikan integrasi strategis dengan kerangka *Customer Relationship Management* (CRM). Selain itu, data ulasan pelanggan sebagai indikator proaktif ketidakpuasan dini masih belum dimanfaatkan secara optimal. Penelitian ini bertujuan membangun model deteksi dini *churn* pelanggan berbasis *machine learning* pada platform *e-commerce*, sekaligus menyelaraskan temuan analitis dengan implementasi CRM yang strategis. Penelitian ini menggunakan dataset ulasan pelanggan *e-commerce* yang diproses melalui tahap *preprocessing*, transformasi data, dan pelabelan *churn* berdasarkan nilai rating. Pelanggan dengan rating rendah dikategorikan sebagai *churn*, sedangkan pelanggan dengan rating tinggi dikategorikan sebagai *non-churn*. Untuk menjamin stabilitas, model klasifikasi dibangun menggunakan algoritma Random Forest dan diperkuat dengan teknik *Cross-Validation*. Penelitian ini menggunakan metode SMOTE (*Synthetic Minority Over-sampling Technique*) untuk mengatasi ketidakseimbangan data. Hasil eksperimen menunjukkan bahwa model Random Forest memiliki akurasi sebesar 99,03 persen, presisi sebesar 76,92 persen, dan recall sebesar 84,42 persen. Temuan ini menegaskan bahwa data ulasan pelanggan memiliki tingkat signifikansi yang tinggi dalam merepresentasikan perilaku pelanggan dan efektif untuk memprediksi potensi *churn* sejak tahap awal interaksi. Penelitian ini menyimpulkan bahwa model yang dikembangkan dapat diintegrasikan ke dalam sistem CRM sebagai pendukung strategi retensi pelanggan yang proaktif dan preventif untuk mempertahankan loyalitas pelanggan dalam jangka panjang.

Kata Kunci: *Customer Churn; E-Commerce; Customer Relationship Management (CRM); Random Forest; Prediksi Churn*

Abstract

The phenomenon of customer churn is a critical challenge in the contemporary *e-commerce* ecosystem, with direct implications for a company's profitability and market share stability. Although the discourse on churn prediction has evolved rapidly, the majority of conventional approaches focus solely on technical transactional parameters, thereby neglecting strategic integration with *Customer Relationship Management* (CRM) frameworks. Furthermore, customer review data—as a proactive indicator of early dissatisfaction—remains underutilized. This study aims to develop a machine learning-based early customer churn detection model for *e-commerce* platforms, while aligning analytical findings with strategic CRM implementation. The study utilizes an *e-commerce* customer review dataset processed through *preprocessing*, data transformation, and churn labeling based on rating values. Customers with low ratings are categorized as *churn*, while those with high ratings are categorized as *non-churn*. To ensure stability, the classification model was built using the Random Forest algorithm and validated using *cross-validation*. This study employed the SMOTE (*Synthetic Minority Over-sampling Technique*) method to address data imbalance. Experimental results show that the Random Forest model has an accuracy of 99.03 percent, a precision of 76.92 percent, and a recall of 84.42 percent. These findings confirm that customer review data holds a high level of significance in representing customer behavior and is effective for predicting potential churn from the early stages of

interaction. This study concludes that the developed model can be integrated into a CRM system to support proactive and preventive customer retention strategies aimed at maintaining long-term customer loyalty.

Keywords: *Customer Churn; E-Commerce; Customer Relationship Management (CRM); Random Forest; Churn Prediction*

1. PENDAHULUAN

Perkembangan teknologi digital telah mendorong pertumbuhan signifikan industri *e-commerce* di berbagai negara dan menjadikan data pelanggan sebagai aset strategis dalam pengambilan keputusan bisnis modern [1]. Intensitas persaingan antar platform *e-commerce* mendorong perusahaan untuk memahami perilaku pelanggan secara lebih mendalam guna mempertahankan loyalitas dan membangun hubungan pelanggan yang berkelanjutan [2]. Seiring dengan hal tersebut, pemanfaatan teknik *machine learning* semakin relevan sebab dapat menganalisis data pelanggan dalam jumlah besar untuk mengidentifikasi berbagai faktor yang memengaruhi perilaku pelanggan secara lebih akurat [3].

Customer churn merupakan salah satu permasalahan utama dalam industri *e-commerce*, yaitu kondisi ketika pelanggan berhenti menggunakan suatu layanan atau berpindah ke platform pesaing [4]. Permasalahan ini menjadi krusial dalam ekosistem digital karena pelanggan memiliki hambatan perpindahan yang rendah dan akses yang luas terhadap alternatif layanan [5]. Jika tidak diidentifikasi sejak dini, tingginya tingkat *customer churn* dapat merugikan perusahaan dan strategi bisnis jangka panjang akibat hilangnya pelanggan [6].

Sejumlah penelitian sebelumnya mengungkapkan bahwa metode *machine learning* dapat dimanfaatkan secara efektif dalam memprediksi kemungkinan *churn* pelanggan melalui analisis data perilaku pelanggan [7]. Penelitian oleh Boukrouh dan Azmani [8] yang menguji beberapa model *machine learning* untuk memprediksi *churn* melaporkan bahwa beragam algoritma klasifikasi termasuk Random Forest, Decision Tree, Gradient Boosting, dan model berbasis *ensemble* mampu mengidentifikasi pola yang berkaitan dengan kemungkinan pelanggan meninggalkan suatu layanan serta membantu mengenali variabel-variabel penting yang mempengaruhi retensi pelanggan. Selain itu, studi terbaru seperti yang dilakukan oleh Ren

[9] mengindikasikan bahwa model prediksi *churn* tidak hanya berfungsi untuk meningkatkan akurasi klasifikasi, tetapi juga dapat dimanfaatkan sebagai dasar dalam menyusun strategi retensi pelanggan pada *e-commerce*.

Namun demikian, kebanyakan studi masih mengutamakan peningkatan kinerja teknis pada model *machine learning* tanpa mengeksplorasi lebih lanjut pemanfaatannya dalam pengambilan keputusan strategis. Penelitian oleh Rahib et al. [3] dan Nagarajan et al. [5] menitikberatkan pada perbandingan performa berbagai algoritma seperti Logistic Regression, Decision Tree, dan Random Forest dalam meningkatkan akurasi prediksi *churn*, sementara Jahan & Sanam [2] memang telah mengusulkan integrasi prediksi *churn* dengan segmentasi dan sistem rekomendasi, namun fokusnya masih terbatas pada peningkatan retensi secara umum dan belum secara spesifik mengaitkan hasil prediksi dengan mekanisme deteksi dini dalam kerangka operasional *Customer Relationship Management* (CRM). Selain itu, sebagian besar penelitian tersebut menggunakan data transaksi, demografi, atau histori penggunaan layanan sebagai sumber utama, sehingga belum banyak yang memanfaatkan data ulasan pelanggan sebagai representasi langsung dari persepsi dan kepuasan pelanggan [10]. Padahal, data ulasan memiliki potensi besar dalam menangkap indikasi awal ketidakpuasan yang dapat berujung pada *churn* [11]. Oleh karena itu, terdapat dua kesenjangan utama dalam penelitian terdahulu, yaitu belum optimalnya integrasi hasil prediksi *churn* ke dalam sistem CRM sebagai dasar pengambilan keputusan retensi, serta masih terbatasnya pemanfaatan data ulasan pelanggan sebagai sumber utama dalam mendeteksi potensi *churn* secara dini pada platform *e-commerce*.

Berdasarkan kesenjangan tersebut, studi ini bertujuan dalam mengembangkan model deteksi dini *customer churn* pada platform *e-commerce* berbasis *Customer Relationship Management* (CRM)


menggunakan algoritma Random Forest. Berbeda dengan penelitian sebelumnya yang umumnya berfokus pada data transaksi atau perilaku pengguna, penelitian ini secara spesifik memanfaatkan data ulasan pelanggan yang direpresentasikan melalui *rating* sebagai indikator tingkat kepuasan untuk mengidentifikasi potensi *churn* secara lebih awal. Lebih lanjut, penelitian ini tidak hanya berhenti pada tahap prediksi, namun sekaligus mengintegrasikan hasil prediksi ke dalam konteks CRM sebagai dasar pengambilan keputusan retensi pelanggan yang lebih strategis dan berbasis data. Penggunaan algoritma *Random Forest* dalam penelitian ini juga tidak semata-mata ditujukan untuk mencapai akurasi yang tinggi, tetapi untuk menangkap hubungan kompleks antar variabel yang berkaitan dengan persepsi dan pengalaman pelanggan [12]. Dengan demikian, kebaruan (*novelty*) penelitian ini terletak pada kombinasi tiga aspek utama: penggunaan data ulasan pelanggan sebagai sumber utama analisis *churn*, penerapan pendekatan deteksi dini (*early detection*) berbasis *machine learning*, serta integrasi hasil prediksi ke dalam kerangka CRM guna mengoptimalkan proses pengambilan keputusan retensi pelanggan yang lebih sistematis dan aplikatif pada konteks *e-commerce* modern.

2. METODOLOGI PENELITIAN

2.1 Kerangka Alur Penelitian

Alur penelitian ini menjelaskan bagaimana Random Forest digunakan untuk klasifikasi *churn* pelanggan secara sistematis. Ini dilakukan untuk memastikan bahwa proses analisis berjalan terstruktur dan menghasilkan model yang optimal. Penelitian ini dilakukan melalui beberapa tahapan yang terstruktur, dimulai dari pengumpulan data, dilanjutkan dengan proses *data preparation* yang meliputi *preprocessing*, transformasi data, dan ekstraksi fitur. Selanjutnya dilakukan pembentukan label *churn* serta penanganan ketidakseimbangan data dengan SMOTE. Data yang telah diproses selanjutnya digunakan dalam proses pembuatan model Random Forest, dan diakhiri dengan pengukuran kinerja model melalui metode *Cross-Validation* untuk menilai sejauh mana model tersebut berfungsi dengan baik. Pendekatan bertahap dalam penelitian ini sejalan dengan praktik umum dalam pengembangan model *machine learning* untuk prediksi *churn* yang meliputi tahapan

preprocessing, pemodelan, dan evaluasi secara sistematis [13][14].



Gambar 1. Alur Proses Penelitian

Pada gambar 1 terlihat alur penelitian klasifikasi *churn* pelanggan yang dimulai dari tahap pengumpulan data, lalu dilanjutkan dengan tahap data, kemudian dilanjutkan dengan tahap *data preparation* yang meliputi proses *preprocessing*, transformasi data, serta ekstraksi fitur. Selanjutnya dilakukan pembentukan label *churn* untuk mengelompokkan pelanggan ke dalam kategori *churn* dan *non-churn* berdasarkan kriteria tertentu. Setelah itu, dilakukan penanganan ketidakseimbangan data menggunakan teknik SMOTE (*Synthetic Minority Over-sampling Technique*) agar distribusi datanya menjadi lebih seimbang. Setelah data selesai diproses, data tersebut digunakan dalam tahap pembuatan model dengan algoritma Random Forest untuk membuat model klasifikasi.

Pada tahap akhir, dilakukan evaluasi model menggunakan metode *Cross-Validation* dengan metrik evaluasi seperti *accuracy*, *precision*, *recall*, dan *confusion matrix* guna mengukur performa model secara menyeluruh. Selain itu, alur penelitian ini dirancang untuk

mendukung implementasi dalam kerangka CRM, di mana hasil prediksi *churn* yang dihasilkan akan digunakan sebagai dasar dalam pengambilan keputusan strategi retensi pelanggan.

2.2 Pengumpulan Data

Penelitian ini menggunakan data ulasan pelanggan yang diperoleh dari platform *e-commerce* Tokopedia sebagai sumber data utama untuk merepresentasikan perilaku pelanggan. Dataset yang digunakan merupakan data sekunder yang diperoleh dari platform Kaggle dengan judul *Tokopedia Product Reviews 2025*, yang dikumpulkan dari aktivitas pelanggan dalam memberikan ulasan terhadap produk pada periode tahun 2025. Data tersebut dikumpulkan secara daring dan dipilih berdasarkan relevansinya terhadap kebutuhan penelitian dalam menganalisis perilaku pelanggan berbasis interaksi. Dari dataset yang digunakan, diperoleh beberapa fitur yang merepresentasikan perilaku pelanggan, antara lain identitas ulasan, isi ulasan, rating produk, dan waktu pemberian ulasan. Data ulasan dalam bentuk teks dimanfaatkan sebagai sumber utama dalam proses ekstraksi fitur untuk mengidentifikasi pola dan karakteristik interaksi pelanggan.

Dataset ini kemudian digunakan sebagai dasar dalam proses analisis untuk mengidentifikasi pola pelanggan yang berpotensi mengalami *churn*. Adapun lokasi penelitian dilakukan secara tidak langsung melalui pengolahan data digital yang diakses secara *online*, sehingga tidak terbatas pada wilayah geografis tertentu. Penggunaan data perilaku pelanggan, termasuk ulasan dan interaksi pengguna, telah banyak digunakan dalam penelitian *churn prediction* karena mampu merepresentasikan tingkat kepuasan dan keterlibatan pelanggan secara tidak langsung [14][15].

2.3 Data Preparation

Data preprocessing merupakan tahap krusial dalam proses *data mining* yang bertujuan untuk meningkatkan kualitas data agar lebih bersih, konsisten, dan siap digunakan dalam proses pemodelan *machine learning*. Tahapan ini meliputi pembersihan data, transformasi, serta penanganan nilai yang hilang untuk memastikan data dapat diolah secara optimal oleh model [16]. Tahapan *preprocessing* yang baik terbukti berpengaruh

signifikan terhadap peningkatan performa model klasifikasi dalam berbagai studi *churn prediction* [17]. Pada tahap ini dilakukan beberapa proses utama sebagai berikut:

1. *Data Cleaning*: Tahap ini dilakukan untuk membersihkan data dari informasi yang tidak relevan, termasuk penghapusan data duplikat dan data yang tidak sesuai dengan tujuan penelitian. Proses ini bertujuan untuk menghindari bias serta meningkatkan kualitas dataset sebelum dilakukan analisis lebih lanjut.
2. *Missing Value Handling*: Penanganan *missing value* dilakukan untuk mengatasi data yang tidak lengkap. Data yang memiliki nilai kosong akan dihapus atau diabaikan agar tidak mempengaruhi hasil pemodelan. Tahap ini penting untuk menjaga konsistensi dan keandalan data.
3. *Data Selection*: Pada tahap ini, dipilih atribut-atribut yang sesuai dengan tujuan penelitian, terutama yang berkaitan dengan cara berperilaku pelanggan. Seleksi atribut bertujuan untuk mengurangi tingkat kesulitan dari data tersebut serta mempercepat proses analisis.
4. *Data Transformation*: Tahap ini mencakup penyesuaian format data agar lebih terstruktur, seperti normalisasi teks dan penyeragaman format penulisan. Transformasi data diperlukan untuk mempermudah proses pengolahan data pada tahap selanjutnya, khususnya dalam ekstraksi fitur berbasis teks.

Melalui tahapan *data preparation* ini, diharapkan dataset yang digunakan memiliki kualitas yang optimal sehingga mampu meningkatkan akurasi dan stabilitas model dalam mengidentifikasi pola pelanggan yang berpotensi mengalami *churn*.

2.4 Transformasi & Ekstraksi Fitur

Pada tahap ini, dijelaskan proses pengolahan data guna mengubah data asli menjadi bentuk angka yang bisa dimanfaatkan dalam proses pemodelan *machine learning*. Data ulasan pelanggan yang pada awalnya berupa teks diproses melalui tahapan *text preprocessing* untuk menghasilkan representasi numerik. Proses ini meliputi pembersihan teks,

penghapusan karakter yang tidak diperlukan, serta transformasi data ke dalam bentuk yang lebih terstruktur. Selanjutnya, ekstraksi fitur dilakukan guna mengetahui informasi penting data ulasan yang dapat merepresentasikan perilaku pelanggan. Tahap ini memiliki tujuan untuk menaikkan kualitas fitur agar dapat digunakan optimal dalam proses klasifikasi. Proses ini merupakan tahapan penting guna meningkatkan kualitas representasi data agar model dapat mengenali pola perilaku konsumen dengan lebih tepat [17][18].

2.5 Pembentukan Label *Churn*

Pada tahap ini dilakukan pembentukan label *churn* untuk membagi pelanggan menjadi dua kelompok, yaitu *churn* dan *non-churn*. Mengingat dataset yang digunakan berupa data ulasan produk, maka penentuan *churn* dalam studi ini didasarkan pada tingkat kepuasan pelanggan, direpresentasikan melalui rating yang diberikan.

Dalam penelitian ini, pelanggan dikategorikan sebagai *churn* apabila memberikan rating rendah, yaitu kurang dari atau sama dengan 3, yang menunjukkan ketidakpuasan terhadap produk atau layanan. Sebaliknya, pelanggan yang memberikan rating lebih dari 3 dikategorikan sebagai *non-churn*, yang mencerminkan tingkat kepuasan yang lebih baik. Pendekatan ini digunakan dengan asumsi bahwa pelanggan yang tidak puas memiliki kecenderungan lebih tinggi untuk berhenti menggunakan layanan atau tidak melakukan pembelian ulang.

Selanjutnya, label *churn* yang telah dibentuk ditetapkan sebagai variabel target menggunakan teknik *set role*, sehingga dapat digunakan dalam proses klasifikasi oleh algoritma Random Forest. Pendekatan berbasis perilaku ini umum digunakan dalam penelitian *churn prediction*, di mana perubahan pola aktivitas pelanggan dijadikan indikator utama dalam menentukan status *churn* [13][18].

2.6 SMOTE (*Balancing Data*)

Dataset yang digunakan dalam penelitian ini tidak seimbang dalam jumlah data antara kelas *churn* dan *non-churn*, sehingga bisa menyebabkan model memihak kelas yang jumlah datanya lebih banyak. Untuk menyelesaikan masalah tersebut, digunakan metode SMOTE (Synthetic Minority Over-sampling Technique) yang sering digunakan dalam penelitian prediksi *churn* untuk

meningkatkan kemampuan model dalam mengenali kelas minoritas. Metode ini menghasilkan data sintesis dari kelas minoritas untuk menciptakan distribusi data yang lebih seimbang [13][19]. Akibatnya, model dapat mengidentifikasi pola di kedua kelas dengan lebih baik.

2.7 Random Forest (*Modeling*)

Pada tahap pembuatan model, digunakan algoritma Random Forest untuk membuat model yang bisa mengklasifikasikan pelanggan yang berpotensi *churn*. Algoritma ini berjalan dengan membuat beberapa pohon keputusan secara acak, lalu menggabungkan hasil ramalan dari setiap pohon tersebut untuk mendapatkan keputusan akhir. Pada penelitian ini, model Random Forest dikonfigurasi dengan parameter *number of trees* sebanyak 100 dan *maximal depth* sebesar 10 untuk mengontrol kompleksitas model. Kriteria pemilihan atribut menggunakan *gain ratio*, yang bertujuan untuk meningkatkan kualitas pemisahan data pada setiap node.

Selain itu, digunakan *subset ratio* secara otomatis (*guess subset ratio*) untuk menentukan jumlah atribut yang dipilih pada setiap pembentukan pohon, serta *voting strategy* berupa *confidence vote* untuk menentukan hasil prediksi akhir berdasarkan tingkat kepercayaan model. Penggunaan konfigurasi parameter ini bertujuan untuk menghasilkan model yang stabil, akurat, serta mampu menangani kompleksitas data dalam prediksi *churn* pelanggan [20][21].

2.8 Evaluasi (*Cross-Validation*)

Tahap evaluasi dilakukan untuk mengukur kinerja model dalam mengklasifikasikan data secara akurat dan memastikan kemampuan generalisasi model terhadap data baru. Dalam penelitian ini, metode *cross-validation* digunakan untuk meminimalkan bias evaluasi dan memberikan estimasi performa model yang lebih stabil, yang merupakan pendekatan umum dalam penelitian *machine learning* [14][15].

Dalam proses evaluasi, pembagian Data divalidasi melalui metode *cross validation* dengan skema *cross validation k-fold*. Dalam penelitian ini, dataset dibagi menjadi 10 bagian (*fold*) dengan ukuran yang sebanding. Evaluasi dilakukan sepuluh kali. Seluruh data dalam dataset akan digunakan secara merata baik sebagai data pelatihan maupun data pengujian

pada setiap iterasi, dengan sembilan *fold* digunakan sebagai data pelatihan dan satu *fold* sisanya digunakan sebagai data pengujian. Selanjutnya, hasil evaluasi dari setiap iterasi dirata-ratakan untuk mendapatkan nilai performa model yang lebih representatif dan stabil.

Kinerja model diukur menggunakan beberapa metrik evaluasi, yaitu *accuracy*, *precision*, *recall*, dan *confusion matrix*, sehingga diperoleh gambaran yang komprehensif terhadap performa model dalam melakukan klasifikasi. Hasil evaluasi model ini selanjutnya diharapkan dapat digunakan sebagai dasar dalam pengambilan keputusan pada sistem CRM, khususnya dalam mengidentifikasi pelanggan yang berisiko *churn* secara dini.

3. HASIL DAN PEMBAHASAN

Bagian ini menampilkan hitungan pengolahan dan analisis data ulasan pelanggan menggunakan Random Forest untuk mengidentifikasi pola perilaku yang berkaitan dengan potensi *churn*. Hasil klasifikasi menunjukkan bahwa pelanggan dibedakan menjadi dua kategori utama, yakni *churn* dan *non-churn*, di mana kelas *non-churn* memiliki proporsi yang lebih banyak.

3.1 Deskripsi Dataset

Kumpulan data yang dipakai terdapat 12.952 data pelanggan yang sudah melalui tahap *preprocessing* dan pelabelan. Berdasarkan distribusi kelas, terdapat 12.644 data pelanggan *non-churn* dan 308 data pelanggan *churn*, yang menunjukkan adanya ketidakseimbangan kelas (*imbalanced*) dengan dominasi pada kelas *non-churn*.


Ketidakseimbangan distribusi kelas yang signifikan ini merupakan karakteristik umum dalam permasalahan *churn prediction* dan berpotensi menyebabkan bias model terhadap kelas mayoritas jika tidak diperhatikan dalam proses analisis [22][23]. Karenanya, penilaian kinerja model bukan semata-mata berfokus pada ketepatan atau akurasi, namun turut mempertimbangkan metrik lain yang mampu merepresentasikan kemampuan model dalam mendeteksi kelas minoritas. Distribusi kelas pelanggan dalam dataset nampak pada tabel 1.

Tabel 1. Distribusi Kelas Pelanggan

Kelas	Jumlah Data
<i>Non-Churn</i>	12.644
<i>Churn</i>	308
Total	12.952

3.2 Proses Pemodelan

Proses pemodelan dilakukan menggunakan platform Altair AI Studio dengan menerapkan Random Forest melalui skema *Cross-Validation*. Model dibangun berdasarkan data yang telah melalui tahap *preprocessing* dan transformasi, serta menggunakan label *churn* sebagai variabel target dalam proses klasifikasi.



Gambar 2. Proses Pemodelan

Dalam proses ini, model dilatih dan diuji untuk mengidentifikasi pola yang membedakan pelanggan *churn* dan *non-churn* berdasarkan data ulasan yang tersedia. Metode ini memberikan kesempatan kepada model dengan tujuan memahami keterkaitan antara fitur dengan cara yang lebih rumit dan juga meningkatkan kemampuan menggunakan pengetahuan pada data yang belum pernah ditemui sebelumnya [16][24].

Hasil dari tahapan pemodelan kemudian dipakai dalam menilai kinerja model guna mengklasifikasikan pelanggan serta menjadi dasar dalam analisis lebih lanjut terhadap pola perilaku pelanggan yang berpotensi mengalami *churn*.

3.3 Evaluasi Model

Hasil penilaian model memperlihatkan model yang dipakai mempunyai performa yang sangat baik dalam membagi pelanggan menjadi dua kelompok, yaitu *churn* dan *non-churn*. Berdasarkan hasil pengujian, diperoleh nilai **akurasi sebesar 99,03%** dengan deviasi sebesar $\pm 0,74\%$, memperlihatkan model mempunyai kualitas konsistensi serta stabilitas yang tinggi.

Tingginya nilai akurasi ini dipengaruhi oleh kualitas *preprocessing* data, representasi fitur yang relevan, serta kemampuan Random Forest mengatasi interaksi non-linear dan rumit dalam data [24][25]. Selain itu, penanganan ketidakseimbangan data juga membantu menaikkan performa model guna mengidentifikasi pola di kelas yang jarang [22].

Namun demikian, dalam konteks dataset yang tidak seimbang, akurasi yang tinggi tidak selalu mencerminkan performa model secara menyeluruh. Oleh sebab itu, digunakan metrik evaluasi tambahan seperti *precision* dan *recall* bertujuan memberi pemahaman lebih menyeluruh terhadap kecakapan model mendeteksi pelanggan *churn* [23].

Tabel 2. Evaluasi Model

Metrik	Nilai
<i>Accuracy</i>	99,03%
<i>Precision (Churn)</i>	76,92%
<i>Recall (Churn)</i>	84,42%


Tabel 2 menunjukkan bahwa model menghasilkan nilai ***precision* sebesar 76,92%** dan ***recall* sebesar 84,42%** pada kelas *churn*. Nilai *precision* memperlihatkan mayoritas prediksi *churn* yang dihasilkan oleh model adalah akurat, sedangkan nilai *recall* memperlihatkan kapasitas model dalam mengidentifikasi mayoritas pelanggan yang benar mengalami *churn*. Tingkat *recall* yang cukup tinggi menjadi indikator penting dalam dunia bisnis, sebab kemampuan mengetahui pelanggan *churn* secara dini lebih krusial dibandingkan sekadar akurasi keseluruhan [26][27].

	true non_churn	true churn
pred. non_churn	12566	48
pred. churn	78	260

Gambar 3. *Confusion Matrix*

Hasil pengelompokkan juga ditampilkan melalui *confusion matrix* guna memperlihatkan sebaran prediksi dibandingkan dengan data yang sebenarnya. Berdasarkan hasil tersebut, model mampu mengelompokkan hampir semua data dengan tepat, baik pada kelas *non-churn* maupun *churn*, dengan jumlah

kesalahan klasifikasi yang tergolong kecil dibandingkan total data. Visualisasi dalam bentuk *heatmap* digunakan untuk memperjelas distribusi prediksi serta memudahkan interpretasi hasil klasifikasi pada tiap kelas.



Gambar 4. Visualisasi *Confusion Matrix* (*Heatmap*)

3.4 Pembahasan

Hasil dari evaluasi model memperlihatkan Random Forest mampu dalam mengidentifikasi pola perilaku pelanggan yang berkaitan dengan potensi *churn* secara efektif. Temuan ini menunjukkan bahwa pendekatan *machine learning* bukan sekedar berperan sebagai alat untuk mengklasifikasikan, namun dapat juga menangkap hubungan kompleks antar fitur yang merepresentasikan perilaku pelanggan dalam ekosistem *e-commerce* [16][24].

Salah satu temuan utama dalam penelitian ini menunjukkan bahwa data ulasan pelanggan memiliki peran signifikan dalam mendeteksi potensi *churn*. Ulasan dari pelanggan menunjukkan seberapa puas mereka terhadap layanan yang diberikan, direpresentasikan melalui rating yang diberi. Pelanggan yang memiliki tingkat kepuasan rendah cenderung memiliki potensi lebih tinggi untuk mengalami *churn*. Hal ini menunjukkan bahwa perilaku pelanggan dapat diidentifikasi sejak tahap awal interaksi, sehingga memungkinkan deteksi *churn* dilakukan secara lebih dini [28][18].

Dari sisi performa model, penggunaan Random Forest terbukti dapat menyediakan model yang lebih stabil dan tepat dalam menangani data dengan kompleksitas tinggi. Ini sejalan dengan penelitian sebelumnya yang menyatakan bahwa teknik *ensemble learning* memiliki keunggulan dalam meningkatkan akurasi serta mengurangi risiko *overfitting* dibandingkan metode klasifikasi tunggal

[24][25]. Oleh karena itu, model yang dibuat tidak hanya memiliki kinerja yang baik, namun juga dapat menjalankan penyamarataan dengan baik terhadap informasi yang baru.

Dalam perspektif *Customer Relationship Management* (CRM), model deteksi dini *churn* yang dihasilkan dapat diintegrasikan sebagai alat pendukung pengambilan keputusan dalam strategi retensi pelanggan sejak tahap awal interaksi. Dengan kemampuan deteksi dini, perusahaan dapat mengidentifikasi pelanggan yang berisiko *churn* sebelum pelanggan benar-benar berhenti berinteraksi, sehingga intervensi dapat dilakukan lebih cepat dan lebih tepat sasaran, seperti pemberian promosi yang dipersonalisasi, pengiriman notifikasi *re-engagement*, atau peningkatan kualitas layanan bagi pelanggan yang terindikasi mengalami penurunan keterlibatan [27].

Lebih lanjut, integrasi antara *machine learning* dan CRM memungkinkan perusahaan untuk mengubah pendekatan yang sebelumnya bersifat reaktif menjadi proaktif dalam mengelola hubungan pelanggan. Dengan memanfaatkan hasil deteksi dini *churn* secara optimal, perusahaan tidak hanya dapat mengurangi tingkat kehilangan pelanggan, tetapi juga meningkatkan loyalitas serta nilai jangka panjang pelanggan (*customer lifetime value*) [27][28].

4. KESIMPULAN

Dari temuan kajian yang dilaksanakan, berikut beberapa kesimpulan yang dapat diberikan:

1. Model Random Forest dapat mengelompokkan pelanggan *churn* dan *non-churn* dengan performa yang sangat baik, ditunjukkan oleh hasil akurasi sejumlah 99,03% serta didukung nilai *precision* dan *recall* yang memadai.
2. Data ulasan pelanggan efektif digunakan untuk merepresentasikan perilaku pelanggan dan mendukung deteksi dini *churn* sejak tahap awal interaksi.
3. Model yang dihasilkan dapat dimanfaatkan dalam kerangka *Customer Relationship Management* (CRM) untuk mendukung strategi retensi pelanggan secara proaktif.
4. Keterbatasan penelitian terletak pada penggunaan satu algoritma dan satu

sumber data, sehingga hasil belum sepenuhnya merepresentasikan seluruh perilaku pelanggan.

5. SARAN

Berikut beberapa anjuran penelitian di masa depan:

1. Melakukan perbandingan dengan algoritma lain atau metode yang lebih kompleks untuk meningkatkan performa model.
2. Menambahkan variasi data, seperti data transaksi atau interaksi pelanggan lainnya, agar model lebih komprehensif.
3. Mengembangkan pendekatan lanjutan seperti analisis sentimen atau Explainable AI (XAI) untuk meningkatkan interpretasi hasil.

DAFTAR PUSTAKA

- [1] S. J. Ch. Gangadhar, R. K. Arora, P. N. Renjith, J. Bamini, and Y. D. Chincholkar, "E-commerce customer churn prevention using machine learning-based business intelligence strategy," *Measurement Sensors*, vol. 27, p. 100728, Mar. 2023, doi: 10.1016/j.measen.2023.100728.
- [2] I. Jahan and T. F. Sanam, "A comprehensive framework for customer retention in E-commerce using machine learning based on churn prediction, customer segmentation, and recommendation," *Electronic Commerce Research*, vol. 26, no. 1, pp. 1–44, Dec. 2024, doi: 10.1007/s10660-024-09936-0.
- [3] M. A. A. Rahib, N. Saha, R. Mia, and A. Sattar, "Customer data prediction and analysis in e-commerce using machine learning," *Bulletin of Electrical Engineering and Informatics*, vol. 13, no. 4, pp. 2624–2633, Jun. 2024, doi: 10.11591/eei.v13i4.6420.
- [4] Y. Zhang and W. Hu, "Customer churn prediction analysis on E-commerce platforms based on improved XGBoost algorithm," *Journal of Computational Methods in Sciences and Engineering*, Aug. 2025, doi: 10.1177/14727978251364455.
- [5] R. Nagarajan, S. S. Raju, and A. Atheeswaran, "Data-Driven Churn Prediction: Evaluating ML models for business retention strategies," *Journal of Computational and Cognitive*

- Engineering, Feb. 2026, doi: 10.47852/bonviewjcce62026861.
- [6] P. C. S. Reddy, Y. Sucharitha, and A. Vivekanand, "Customer Churn Prevention For E-commerce Platforms using MachineLearning-based Business Intelligence," *Recent Advances in Electrical & Electronic Engineering (Formerly Recent Patents on Electrical & Electronic Engineering)*, vol. 17, no. 5, pp. 456–465, Jul. 2023, doi: 10.2174/2352096516666230717102625.
- [7] Q. Wei, "Personalized and contextualized data analysis for E-Commerce customer retention improvement with Bi-LSTM Churn Prediction," *IEEE Transactions on Consumer Electronics*, vol. 71, no. 2, pp. 4406–4414, Apr. 2024, doi: 10.1109/tce.2024.3376672.
- [8] I. Boukrouh and A. Azmani, "Explainable machine learning models applied to predicting customer churn for e-commerce," *IAES International Journal of Artificial Intelligence*, vol. 14, no. 1, p. 286, Nov. 2024, doi: 10.11591/ijai.v14.i1.pp286-297.
- [9] H. Ren, "Machine Learning-Based prediction of customer churn risk in e-commerce," *Advances in Economics Management and Political Sciences*, vol. 153, no. 1, pp. 47–52, Jan. 2025, doi: 10.54254/2754-1169/2024.19473.
- [10] S. Kumar, S. Deep, and P. Kalra, "A Comprehensive Analysis of Machine Learning Techniques for churn Prediction in E-Commerce: A Comparative study," *International Journal of Computer Trends and Technology*, vol. 72, no. 5, pp. 163–170, May 2024, doi: 10.14445/22312803/ijctt-v72i5p119.
- [11] A. Manzoor, M. A. Qureshi, E. Kidney, and L. Longo, "A review on machine learning methods for customer churn prediction and recommendations for business practitioners," *IEEE Access*, vol. 12, pp. 70434–70463, Jan. 2024, doi: 10.1109/access.2024.3402092.
- [12] T. Wang, "Risk assessment of customer churn in e-commerce platforms by integrating RF algorithm and extreme gradient boosting algorithm," *Service Oriented Computing and Applications*, Jun. 2025, doi: 10.1007/s11761-025-00455-w.
- [13] S. K. Wagh, A. A. Andhale, K. S. Wagh, J. R. Pansare, S. P. Ambadekar, and S. H. Gawande, "Customer churn prediction in telecom sector using machine learning techniques," *Results in Control and Optimization*, vol. 14, p. 100342, Mar. 2024, doi: 10.1016/j.rico.2023.100342.
- [14] Y. Suh, "Machine learning based customer churn prediction in home appliance rental business," *Journal of Big Data*, vol. 10, no. 1, Apr. 2023, doi: 10.1186/s40537-023-00721-8.
- [15] R. Krishna, D. Jayanthi, D. S. Shylu Sam, K. Kavitha, N. K. Maurya, and T. Benil, "Application of machine learning techniques for churn prediction in the telecom business," *Results in Engineering*, vol. 24, p. 103165, Dec. 2024, doi: 10.1016/j.rineng.2024.103165.
- [16] M. Imani, M. Joudaki, A. Beikmohammadi, and H. Arabnia, "Customer Churn Prediction: A Systematic Review of Recent Advances, Trends, and Challenges in Machine Learning and Deep Learning," *Machine Learning and Knowledge Extraction*, vol. 7, no. 3, p. 105, Sep. 2025, doi: 10.3390/make7030105.
- [17] J. K. Sana, M. Z. Abedin, M. S. Rahman, and M. S. Rahman, "A novel customer churn prediction model for the telecommunication industry using data transformation methods and feature selection," *PLOS ONE*, vol. 17, no. 12, p. e0278095, Dec. 2022, doi: 10.1371/journal.pone.0278095.
- [18] V. Chang, K. Hall, Q. Xu, F. Amao, M. Ganatra, and V. Benson, "Prediction of Customer Churn Behavior in the Telecommunication Industry Using Machine Learning Models," *Algorithms*, vol. 17, no. 6, p. 231, May 2024, doi: 10.3390/a17060231.
- [19] M. Z. Alotaibi and M. A. Haq, "Customer Churn Prediction for Telecommunication Companies using Machine Learning and Ensemble Methods," *Engineering, Technology & Applied Science Research*, vol. 14, no. 3, pp. 14572–14578, Jun. 2024, doi: 10.48084/etasr.7480.
- [20] A. Dhini and M. Fauzan, "Predicting Customer Churn using ensemble learning: Case Study of a Fixed Broadband Company," *International Journal of*

- Technology*, vol. 12, no. 5, p. 1030, Dec. 2021, doi: 10.14716/ijtech.v12i5.5223.
- [21] I. Ullah, B. Raza, A. K. Malik, M. Imran, S. U. Islam, and S. W. Kim, "A Churn Prediction Model Using Random Forest: Analysis of Machine Learning Techniques for Churn Prediction and Factor Identification in Telecom Sector," *IEEE Access*, vol. 7, pp. 60134–60149, 2019, doi: 10.1109/access.2019.2914999.
- [22] S. J. Haddadi, A. Farshidvard, F. dos S. Silva, J. C. dos Reis, and M. da Silva Reis, "Customer churn prediction in imbalanced datasets with resampling methods: A comparative study," *Expert Systems with Applications*, vol. 246, p. 123086, Jul. 2024, doi: 10.1016/j.eswa.2023.123086.
- [23] P. Branco, L. Torgo, and R. P. Ribeiro, "A Survey of Predictive Modeling on Imbalanced Domains," *ACM Computing Surveys*, vol. 49, no. 2, pp. 1–50, Aug. 2016, doi: 10.1145/2907070.
- [24] D. Asif, M. S. Arif, and A. Mukheimer, "A data-driven approach with explainable artificial intelligence for customer churn prediction in the telecommunications industry," *Results in Engineering*, vol. 26, p. 104629, Jun. 2025, doi: 10.1016/j.rineng.2025.104629.
- [25] N. Kumar, "An Explainable Hybrid Machine Learning Framework for Customer Churn Prediction," *International Journal of Innovative Research in Technology*, vol. 12, no. 7, Dec. 2025, doi: 10.64643/ijirtv12i7-189194-459.
- [26] P. Jiang, Z. Liu, M. Z. Abedin, J. Wang, W. Yang, and Q. Dong, "Profit-driven weighted classifier with interpretable ability for customer churn prediction," *Omega*, vol. 125, p. 103034, Jun. 2024, doi: 10.1016/j.omega.2024.103034.
- [27] M. G. Abdelhady and Karim. A. Mohamed, "Leveraging artificial intelligence for predictive customer churn modeling in telecommunications: a framework for enhanced customer relationship management," *Scientific Reports*, vol. 15, no. 1, p. 43826, Dec. 2025, doi: 10.1038/s41598-025-30108-z.
- [28] H. Zhang and W. Zhang, "Application of GWO-attention-ConvLSTM model in customer churn prediction and satisfaction analysis in customer relationship management," *Heliyon*, vol. 10, no. 17, Sep. 2024, doi: 10.1016/j.heliyon.2024.e37229.