

Implementasi Algoritma Random Forest Untuk Prediksi Churn Pada Pelanggan Retail Online

Muhammad Haris Khoirul Anam¹, Diva Kurnianingtyas², Arief Andy Soebroto³

Program Studi Teknik Informatika, Fakultas Ilmu Komputer, Universitas Brawijaya
Email: 1Haris_anam@ub.ac.id, 2diva.kurnianingtyas@ub.ac.id, 3ariefas@ub.ac.id

Abstrak

Studi ini menganalisis prediksi pelanggan yang akan berhenti berlangganan (churn) di ritel online untuk membantu perusahaan mengembangkan strategi retensi yang lebih tepat sasaran. Data yang digunakan adalah dataset berisi 1.000 catatan pelanggan ritel online dengan 14 variabel prediktor dan 1 variabel target (Target_Churn). Untuk memastikan data siap untuk pemodelan, dilakukan langkah pra-pemrosesan, termasuk pengecekan kualitas data, transformasi fitur kategorikal dengan one-hot encoding, dan standarisasi fitur numerik. Dataset kemudian dibagi menjadi data pelatihan dan pengujian dengan rasio 70:30 menggunakan pengambilan stratified sampling. Model klasifikasi dibangun menggunakan algoritma Random Forest, dan optimasi hyperparameter dilakukan menggunakan GridSearchCV dengan Cross Validation 5-fold untuk mendapatkan konfigurasi terbaik. Hasil pengujian menunjukkan bahwa model mencapai akurasi 48,33% dan nilai AUC-ROC 0,4825, yang menunjukkan bahwa kemampuannya untuk membedakan antara kelas churn dan non-churn masih rendah pada dataset yang digunakan. Namun, analisis kepentingan fitur mengungkapkan bahwa faktor-faktor yang terkait dengan transaksi dan kepuasan pelanggan cenderung memiliki dampak yang lebih besar daripada karakteristik demografis. Kesimpulan dari penelitian ini adalah bahwa model random forest belum dapat memberikan prediksi churn yang andal pada dataset ini, dan oleh karena itu, diperlukan data yang lebih representatif, penyertaan karakteristik perilaku, atau pengujian metode lain untuk meningkatkan kinerja.

Kata kunci: *churn pelanggan; Random Forest; pembelajaran mesin; hyperparameter tuning; ritel online*

Abstract

This study analyzes customer churn prediction in online retail to help businesses develop more targeted retention strategies. The data used is a dataset of 1,000 online retail customer records with 14 predictor variables and 1 target variable (Target_Churn). A preprocessing stage was performed to ensure the data was ready for modeling, including data quality checks, one-hot encoding of categorical features, and standardization of numerical features. The dataset was then split into training and test data in a 70:30 ratio using stratified sampling. A classification model was built using the Random Forest algorithm, and hyperparameter optimization was performed using GridSearchCV with 5x cross-validation to obtain the best configuration. The test results showed that the model achieved 48.33% accuracy and an AUC-ROC value of 0.4825, indicating that its ability to distinguish between churn and non-churn classes was still low in the dataset used. However, the feature importance analysis showed that transaction-related and customer satisfaction features tended to be more influential than demographic attributes. The conclusion of this study is that the Random Forest model in this dataset cannot yet provide reliable churn predictions, and therefore more representative data, the incorporation of behavioral features, or the testing of other methods are needed to improve performance.

Keywords: *customer churn; Random Forest; machine learning; hyperparameter Tuning; online retail.*

1. PENDAHULUAN

Studi terkini menunjukkan bahwa penggunaan model berbasis data dalam ritel

dapat meningkatkan manajemen inventaris, memenuhi permintaan pelanggan, dan meningkatkan retensi pelanggan (Sweidan et al., 2022). Penerapan analitik big data dalam sektor

ritel telah terbukti secara signifikan meningkatkan kinerja operasional dan finansial perusahaan dengan memfasilitasi pengambilan keputusan yang lebih efektif di lingkungan bisnis yang kompetitif (Lutfi et al., 2023). Penggunaan model machine learning dinilai memberikan keunggulan kompetitif karena algoritma dapat menganalisis data besar dengan cepat untuk menghasilkan keputusan yang lebih berkualitas daripada pendekatan tradisional (English et al., 2021; Geiler, Affeldt and Nadif, 2022).

Dalam perkembangan penelitian sebelumnya, beberapa pendekatan telah diterapkan dalam konteks ini mencakup model regresi, pohon keputusan (Decision Tree), dan algoritma pengelompokan. Namun, setiap model memiliki kelebihan dan kekurangan terkait akurasi dan kompleksitas pemrosesan data (Geiler, Affeldt and Nadif, 2022; Sapara and Patel, 2024). Mengadopsi teknologi baru tidak hanya meningkatkan efisiensi operasional, tetapi juga memungkinkan perusahaan merespon perubahan perilaku pasar dengan cepat (Wilson, Brown and Johnson, 2024).

Penerapan metode tersebut menjadi sangat relevan dalam industri E-commerce yang telah muncul sebagai model bisnis yang sangat berdampak secara global. Inti dari operasi dan pengambilan keputusan e-commerce adalah data pengguna, yang mencakup detail demografi, riwayat pembelian, kebiasaan browsing, dan interaksi pengguna (Laudon and Traver, 2019). Di balik banyaknya aspek data tersebut, pihak e-commerce menyadari tantangan signifikan yang seringkali dihadapi yakni adalah churn pelanggan, yang terjadi ketika pelanggan berhenti melakukan pembelian atau berinteraksi dengan suatu merek (Ahmad, Jafar and Aljoumaa, 2019).

Masalah ini sering kali dikaitkan dengan ketidakpuasan terhadap produk atau kualitas layanan. Data menunjukkan bahwa tingkat churn yang tinggi dapat menyebabkan kerugian pendapatan yang cukup besar, sehingga mendorong perusahaan untuk mengadopsi strategi retensi yang efektif (Sweidan et al., 2022). Penelitian menunjukkan bahwa perusahaan yang berinvestasi dalam analitik data dapat memperkirakan churn pelanggan dengan lebih akurat, memungkinkan tindakan pencegahan tepat waktu sebelum pelanggan memutuskan hubungan (Geiler, Affeldt and Nadif, 2022; Raji et al., 2024).

Di antara berbagai algoritma yang tersedia

untuk menangani kasus tersebut, Random Forest telah terbukti efektif dalam memprediksi churn pelanggan. Random Forest adalah teknik ensemble yang menggabungkan hasil dari banyak pohon keputusan untuk menghasilkan prediksi yang lebih akurat (Geiler, Affeldt and Nadif, 2022; Chang et al., 2024). Algoritma ini memiliki kemampuan khusus untuk menangani data yang tidak seimbang, yang umum ditemukan saat menganalisis churn. Keunggulan utamanya adalah kemampuan mengurangi risiko overfitting, yang sering kali terjadi pada model yang lebih kompleks (Geiler, Affeldt and Nadif, 2022; Sweidan et al., 2022). Selain itu, Random Forest juga dapat memberikan wawasan tentang pentingnya berbagai variabel (feature importance) dalam keputusan pelanggan untuk berhenti, memberi perusahaan informasi berharga dalam perumusan strategi pemasaran yang lebih proaktif (Geiler, Affeldt and Nadif, 2022).

Melihat kompleksitas dan dinamisme pasar e-commerce saat ini, penting bagi pemangku kepentingan untuk mengadopsi teknologi canggih seperti Random Forest untuk menganalisis data pengguna. Dengan memanfaatkan wawasan yang diperoleh, perusahaan dapat mengenali pola perilaku yang relevan dan mengambil tindakan yang tepat untuk mengurangi churn. Penelitian menegaskan bahwa identifikasi pola perilaku pelanggan melalui model pembelajaran mesin sangat penting untuk meminimalkan risiko kehilangan pelanggan dan memastikan profitabilitas jangka panjang perusahaan (Matuszelański and Kopczewska, 2022). Oleh karena itu, memahami dan mengimplementasikan algoritma yang tepat menjadi krusial bagi sukses jangka panjang perusahaan ritel online di era digital ini.

2. PERSAMAAN MATEMATIKA

Pembahasan kemudian berlanjut pada teori Data Mining dan Machine Learning sebagai pendekatan teknis untuk menyelesaikan masalah tersebut. Secara spesifik, bab ini mendalami algoritma Random Forest (Geiler, Affeldt and Nadif, 2022), mulai dari prinsip kerja ensemble, penanganan imbalance data, hingga parameter optimasi. Terakhir, dijelaskan mengenai metrik Evaluasi Model untuk mengukur kinerja prediksi. Kesimpulannya, seluruh teori ini dipaparkan untuk membangun landasan ilmiah yang kokoh dalam menjustifikasi penerapan

Random Forest sebagai solusi prediksi *churn* pada penelitian ini

Penggunaan machine learning untuk prediksi *churn* telah digunakan di berbagai bidang terutama pada lingkup jasa dan layanan telekomunikasi seperti beberapa penelitian yang dapat dilihat pada tabel berikut:

Tabel 2.1 Contoh penelitian sebelumnya tentang prediksi churn

No	Peneliti (Tahun)	Lingkup Studi	Algoritma Utama	Hasil Penelitian
1	Gurung et al. (2024)	Pasar Bisnis (USA)	Random Forest, Decision Tree	Random Forest menunjukkan performa yang lebih baik dan stabil dibandingkan Decision Tree dalam memprediksi perilaku pasar.
2	Muthmainnah & Voutama (2023)	Retail Fashion	Random Forest, XGBoost, Decision Tree	Random Forest menjadi salah satu model terbaik dengan akurasi mencapai 100%, setara dengan XGBoost dan Decision Tree.
3	Wu et al. (2021)*	Industri Telekomunikasi	Random Forest, Logistic Regression	Kombinasi metode klasifikasi dengan teknik SMOTE dan clustering terbukti efektif menargetkan pelanggan berisiko churn.
4	Husein & Harahap (2021)	Sektor Perbankan	Random Forest, K-NN, SVM	Random Forest menjadi model terbaik dengan akurasi 86%, mengungguli K-NN yang memiliki akurasi 84%.

5	Tran et al. (2023)	Sektor Perbankan	Random Forest, K-Means	Random Forest adalah model paling akurat (97,25%) setelah diterapkan segmentasi pelanggan menggunakan K-Means.
---	--------------------	------------------	------------------------	--

2.1 Churn Pelanggan

Churn pelanggan atau bisa disebut *customer agitation* merupakan fenomena ketika pelanggan memutuskan untuk menghentikan penggunaan produk atau layanan dari suatu perusahaan (Tran, Le and Nguyen, 2023). Menurut penelitian, faktor penyebab utama churn ini mencakup kepuasan pelanggan, pengalaman berbelanja, kualitas harga produk, dan efektivitas promosi (Shu-li et al., 2021). Misalnya, rendahnya kepuasan pelanggan akibat pengalaman berbelanja yang buruk dapat mengakibatkan mereka memilih kompetitor lain (Rachid et al., 2018). Dalam konteks bisnis ritel online, churn pelanggan dapat menyebabkan penurunan pendapatan dan peningkatan biaya akuisisi pelanggan baru, secara langsung mempengaruhi profitabilitas dan pertumbuhan perusahaan (Huang et al., 2015).

2.2 Machine Learning

2.2.1 Pengertian Machine Learning

Pembelajaran mesin atau machine learning adalah cabang dari kecerdasan buatan yang memungkinkan sistem komputer untuk belajar dari data mengidentifikasi pola, serta membuat keputusan dengan keterlibatan manusia dengan sangat minimal. Machine learning didefinisikan oleh Tom M. Mitchell pada tahun 1997 sebagai program yang belajar dari sebuah pengalaman *E* terhadap suatu task *T* dimana performanya diukur oleh *P*, dengan nilai performa pada *T* yang diukur oleh *P* akan berimprovisasi dengan pengalaman *E*.

Untuk memahami *machine learning* secara utuh, penting untuk menempatkannya dalam konteks bidang ilmu komputer yang lebih luas. Hubungan antara *Artificial Intelligence*,

Machine learning, dan *Deep Learning* dapat digambarkan secara hierarkis :

1. Kecerdasan Buatan (AI): Merupakan bidang ilmu komputer yang paling luas, dengan tujuan menciptakan sistem yang mampu melakukan tugas-tugas yang umumnya memerlukan kecerdasan manusia.
2. Machine Learning (ML): Adalah sebuah sub-bidang dari AI yang menyediakan metode untuk mencapai kecerdasan buatan dengan cara belajar dari data, bukan melalui pemrograman eksplisit.
3. Deep Learning (DL): Merupakan sub-bidang dari ML yang secara spesifik menggunakan arsitektur jaringan syaraf tiruan dengan banyak lapisan (dikenal sebagai *deep neural networks*) untuk mempelajari representasi data yang semakin kompleks dan abstrak.

2.2.2 Supervised Learning

Pembelajaran terawasi menggunakan data berlabel untuk melatih model (Tavasoli, 2025). Dalam konteks prediksi *churn*, data historis dari pelanggan yang statusnya (*churn* atau tidak) diketahui digunakan untuk melatih model.

2.2.3 Unsupervised Learning

Unsupervised learning bekerja dengan data tanpa label, mencari pola tersembunyi dalam data (Tavasoli, 2025). Teknik ini sering digunakan untuk segmentasi pelanggan sebelum analisis *churn* seperti K-Means Clustering, Hierarchical Clustering, dan Principal Component Analysis (PCA),

2.2.4 Reinforcement Learning

Reinforcement learning menggunakan sistem reward dan punishment untuk membuat keputusan optimal. Meskipun jarang digunakan langsung untuk prediksi *churn*, teknik ini dapat diterapkan untuk optimasi strategi retensi pelanggan beberapa diantaranya Q-learning, Deep Q-Networks (DQN), Monte Carlo Tree Search (MCTS).

2.2.5 Pembelajaran Mesin dalam Prediksi Churn

Dalam e-commerce, penerapan pembelajaran mesin sangat berharga dalam

menganalisis dan memprediksi *churn* pelanggan (Faris, 2018). algoritma yang sering digunakan dalam prediksi *churn* mencakup regresi logistik, pohon keputusan (Decision Tree), Support Vector Machine (SVM), dan jaringan syaraf (Neural Networks) (Ahn et al., 2020; Jain, Khunteta and Srivastava, 2020). Studi menunjukkan bahwa metode ensemble, seperti Random Forest, sering kali menghasilkan akurasi prediksi yang lebih tinggi dan mengurangi *overfitting* dibandingkan dengan metode prediksi tunggal lain (Guliyev and Tatoğlu, 2021; Tran, Le and Nguyen, 2023) membantu menciptakan ekosistem ritel yang lebih responsif dan dinamis, menyesuaikan dengan kebutuhan dan harapan pelanggan yang terus berubah.

2.2.6 Random Forest

Random Forest adalah algoritma pembelajaran mesin berbasis *ensemble learning* yang bekerja dengan membangun beberapa pohon keputusan dan mengeluarkan prediksi berdasarkan mayoritas suara dari semua pohon tersebut. metode ini dikembangkan oleh (Breiman, 2001) untuk menghasilkan tingkat akurasi node yang tinggi pada pembangkitan atributnya. Random Forest terbentuk dari kumpulan decision tree yang digunakan untuk mengklasifikasi data ke dalam kelas. Kelebihannya termasuk kemampuannya untuk menangani data yang besar dan kompleks dengan baik serta ketahanannya terhadap *overfitting*, secara signifikan meningkatkan akurasi prediksi (Deng, 2024; Sam, Asuquo and Stephen, 2024). Namun, meskipun algoritma ini kuat, kekurangannya terletak pada kemampuannya yang lebih rendah dalam memberikan interpretasi atau penjelasan yang jelas daripada metode yang lebih sederhana, seperti regresi logistik (Wen, 2023).

Random Forest telah diterapkan secara luas dalam prediksi *churn* pelanggan karena kemampuannya untuk mengidentifikasi fitur yang paling berkaitan dengan *churn*, sehingga memungkinkan perusahaan untuk menargetkan intervensi lebih efektif (Chang et al., 2024).

2.2.7 Cara Kerja Random Forest

Dalam implementasinya random forest memiliki cara kerja sebagai berikut

1. Bootstrap Aggregating (Bagging)

Random Forest menggunakan teknik bootstrap sampling untuk membuat subset data training yang berbeda untuk setiap pohon:

$D_i = \text{Bootstrap sample dari } D \text{ dengan ukuran } n \text{ (1)}$

2. Random Feature Selection

Pada setiap node split, Random Forest hanya mempertimbangkan subset acak dari fitur:

$$m = \sqrt{p} \quad (2)$$

3. Konstruksi Pohon

Setiap pohon dibangun menggunakan kriteria pemisahan seperti Gini Impurity:

$$Gini = 1 - \sum_{i=1}^c p_i^2 \quad (3)$$

Atau Information Gain berdasarkan Entropy:

$$Entropy = - \sum_{i=1}^c p_i \log_2(p_i) \quad (4)$$

$$Information\ Gain = Entropy_{parent} - \sum_j \frac{n_j}{n} \times entropy_j \quad (5)$$

4. Agregasi Prediksi

Untuk klasifikasi, prediksi akhir ditentukan melalui majority voting:

$$\hat{y} = \text{mode} \{h_1(x), h_2(x), \dots, h_B(x)\} \quad (6)$$

Parameter Penting Random Forest:

1. **n_estimators:** Jumlah pohon dalam forest (default: 100)
2. **max_depth:** Kedalaman maksimum setiap pohon
3. **min_samples_split:** Jumlah minimum sampel yang diperlukan untuk split node
4. **min_samples_leaf:** Jumlah minimum sampel di leaf node
5. **max_features:** Jumlah fitur yang dipertimbangkan untuk split terbaik

Pemilihan nilai parameter secara langsung memengaruhi kemampuan generalisasi model. Oleh karena itu, implementasi proses optimasi hyperparameter sangat penting untuk memastikan bahwa model berkinerja efektif

pada data pelatihan dan tetap stabil ketika dihadapkan pada data baru.

2.2.8 GridSearchCV

Grid Search adalah metode optimasi yang banyak diadopsi yang secara sistematis mengeksplorasi kombinasi hyperparameter dalam ruang kandidat yang telah ditentukan untuk mengidentifikasi konfigurasi optimal (Sholeh, Lestari and Andayati, 2025). Selama proses optimasi, kinerja setiap kombinasi hyperparameter harus dinilai menggunakan *Cross Validation*. *Cross Validation* membagi data pelatihan menjadi beberapa bagian sehingga model diuji berulang kali pada partisi yang berbeda, menghasilkan estimasi kinerja yang lebih stabil dan mengurangi bias karena pemilihan data uji secara acak (Sholeh, Lestari and Andayati, 2025). Penerapan validasi silang juga umum dalam studi prediksi churn untuk mendapatkan evaluasi yang lebih kuat, misalnya, menggunakan skema pengujian model 10-fold (Suh, 2023).

2.3 Data dan Evaluasi Model

Dalam membangun model prediksi *churn*, jenis data yang digunakan memainkan peran sangat penting. Variabel yang umumnya dipertimbangkan termasuk demografi pelanggan, riwayat belanja, dan interaksi dengan layanan pelanggan (Xu, Ma and Kim, 2021). Proses preprocessing data, termasuk penanganan ketidakseimbangan kelas dalam dataset, juga krusial untuk memastikan model yang dibangun efektif dan akurat. Teknik seperti undersampling dan oversampling dapat diterapkan untuk menyeimbangkan jumlah data churn dan non-churn (Rekha, Tyagi and Reddy, 2019; Ambildhuke, Rekha and Tyagi, 2021). Untuk memastikan model memiliki tingkat prediksi yang baik, digunakan metrik evaluasi yang disebut Confusion Matrix. Metrik ini digunakan untuk membandingkan performa model *Random Forest* dengan memetakan hasil prediksi terhadap data aktual (Ehsani and Hosseini, 2024).

Tabel 2.2 Tabel confusion matrix

	Predicted Churn	Predicted Non-Churn
Actual Churn	True Positive (TP)	False Negative (FN)

Actual Non Churn	False Positive (FP)	True Negative (TN)
------------------	---------------------	--------------------

Berdasarkan komponen *Confusion Matrix* (TP, TN, FP, FN) pada tabel 2.2, efektivitas model dinilai menggunakan persamaan matematis berikut:

1. Akurasi, Mengukur persentase prediksi yang benar dibandingkan dengan keseluruhan data uji.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (7)$$

2. Precision, Mengukur berapa banyak dari prediksi churn yang benar-benar churn.

$$Precision = \frac{TP}{TP + FP} \quad (8)$$

3. Recall (Sensitivity): Mengukur seberapa banyak churn yang benar-benar terdeteksi oleh model.

$$Recall = \frac{TP}{TP + FN} \quad (9)$$

4. F1-Score, Rata-rata harmonik dari precision dan recall, memberikan keseimbangan antara keduanya.

$$F1 = 2x \frac{Precision \times Recall}{Precision + recall} \quad (10)$$

5. AUC-ROC (Area Under Curve - Receiver Operating Characteristic): Metrik yang mengukur seberapa baik model dapat membedakan antara pelanggan churn dan non-churn. Salah satu komponen pembentuk kurva ROC adalah *False Positive Rate* (FPR)

$$FPR = \frac{FP}{FP + TN} \quad (11)$$

Dengan menggunakan teknik evaluasi ini, perusahaan dapat lebih memahami performa model dan membuat keputusan yang lebih informasional terkait strategi retensi pelanggan.


3. METODOLOGI PENELITIAN

Metode penelitian disusun sebagai eksperimen komputasional yang mencakup pengumpulan data, pra-pemrosesan, pelatihan model, optimasi hyperparameter, dan evaluasi

kinerja.

3.1 Dataset

Data yang digunakan berasal dari



Gambar 3.1 Diagram alir metode penelitian

dataset publik Online Retail Customer Churn (Eskikri, 2023) dengan 1.000 catatan pelanggan. Dataset mencakup 15 kolom, terdiri dari satu atribut identitas (Customer_ID), 13 atribut prediktor numerik/kategorikal, satu atribut kategorikal terkait respons promosi, serta satu label target biner (Target_Churn). Atribut identitas tidak digunakan sebagai fitur prediktor sehingga dihapus pada tahap pembersihan data.

3.2 Pra-pemrosesan Data

Pra-pemrosesan dilakukan untuk memastikan data dapat diproses oleh model. Tahapan yang diterapkan meliputi (1) pemeriksaan nilai hilang dan duplikasi, (2) penghapusan Customer_ID, (3) transformasi variabel kategorikal menggunakan one-hot encoding (Gender dan Promotion_Response), (4) encoding variabel biner (Target_Churn dan Email_Opt_In) menjadi 0/1, dan (5) normalisasi fitur numerik menggunakan MinMaxScaler untuk memetakan nilai ke rentang [0,1].

3.3 Pemodelan Random Forest dan Optimasi Hyperparameter

Model klasifikasi dibangun menggunakan RandomForestClassifier. Untuk memperoleh konfigurasi yang lebih sesuai

dengan karakteristik data, dilakukan optimasi hyperparameter menggunakan GridSearchCV. Grid search mengeksplorasi kombinasi parameter secara sistematis dalam ruang kandidat dan memilih konfigurasi terbaik berdasarkan kinerja validasi (Sholeh, Lestari and Andayati, 2025). Proses pencarian menggunakan 5-fold cross-validation pada data latih dengan metrik F1 sebagai fungsi skor, karena F1 menyeimbangkan precision dan recall pada klasifikasi biner.

3.4 Evaluasi Kinerja

Dataset dibagi menjadi data latih dan data uji dengan rasio 70:30 menggunakan stratified sampling untuk menjaga proporsi kelas. Kinerja model dievaluasi menggunakan confusion matrix dan metrik Accuracy, Precision, Recall, F1-Score, serta AUC-ROC. AUC-ROC digunakan untuk menilai kemampuan model membedakan dua kelas secara agregat pada berbagai ambang keputusan (Suh, 2023).

4. HASIL DAN PEMBAHASAN


Bagian ini menyajikan hasil optimasi hyperparameter, performa model pada data uji, serta interpretasi feature importance.

Tabel 1. Konfigurasi terbaik hasil GridSearchCV

Hyperparameter	Nilai terbaik
criterion	entropy
max depth	10
min samples split	10
n estimators	100
cv	5-fold
scoring	F1-Score

4.1 Hasil Confusion Matrix

Confusion Matrix memberikan gambaran detail mengenai jumlah kesalahan prediksi yang dilakukan oleh model, baik itu *False Positive* maupun *False Negative*. Gambar 4.1 menunjukkan distribusi prediksi model dibandingkan dengan label aktual.




Gambar 4.2 Visualisasi Confusion matrix prediksi churn

4.2 Hasil Performa Model

Tabel 2. Performa model pada data uji (n=300)

Metrik	Nilai	Persentase
Accuracy	0.4833	48.33%
Precision	0.5078	50.78%
Recall	0.6203	62.03%
F1-Score	0.5584	55.84%
AUC-ROC	0.4825	-

Berdasarkan confusion matrix, model menghasilkan True Positive (TP)=98, False Negative (FN)=60, False Positive (FP)=95, dan True Negative (TN)=47. Komposisi ini menunjukkan model cenderung lebih sensitif mendeteksi pelanggan churn (recall relatif lebih tinggi), namun masih menghasilkan false positive yang besar, sehingga akurasi keseluruhan menurun.




Gambar 4.3 Visualisasi kurva ROC

Nilai AUC-ROC sebesar 0,4825 berada di bawah 0,50 yang biasa dipandang sebagai batas pemisahan acak, sehingga model belum mampu membedakan kelas churn dan non-churn secara memadai pada dataset yang digunakan. Distribusi kelas yang relatif seimbang (526 churn dan 474 non-churn) membuat baseline prediksi kelas mayoritas berada pada kisaran 52,6%. Akurasi model yang lebih rendah dari baseline mengindikasikan bahwa pola yang terbentuk dari fitur yang tersedia belum cukup informatif, atau terdapat tumpang tindih yang tinggi antar kelas.

4.3 Hasil Feature Importance

Analisis Feature Importance dilakukan untuk mengidentifikasi atribut yang paling berpengaruh dalam keputusan model. Berikut adalah 5 fitur teratas berdasarkan bobot kepentingannya:



Gambar 4.4 Feature importance dalam prediksi churn

Walaupun demikian, analisis feature importance memberikan perspektif yang bernilai. Variabel yang berkaitan dengan transaksi seperti Average_Transaction_Amount, Annual_Income, dan Total_Spend muncul sebagai kontributor utama. Secara bisnis, temuan ini sejalan dengan pemahaman bahwa nilai moneter dan intensitas transaksi sering menjadi penanda keterikatan pelanggan. Ke depan, peningkatan performa dapat diarahkan melalui pengayaan fitur perilaku (misalnya pola waktu transaksi, frekuensi kunjungan, atau riwayat interaksi layanan yang lebih rinci), pengaturan ambang keputusan berbasis tujuan bisnis, serta perbandingan dengan algoritma lain seperti metode boosting.

5. KESIMPULAN DAN SARAN

Penelitian ini mengimplementasikan Random Forest untuk prediksi customer churn pada ritel online dengan optimasi hyperparameter menggunakan GridSearchCV dan validasi silang 5-fold. Pada dataset publik yang digunakan, model terbaik memperoleh akurasi 48,33% dan AUC-ROC 0,4825, menunjukkan bahwa kemampuan klasifikasi masih terbatas. Meski performa prediksi belum memadai, feature importance mengindikasikan bahwa fitur berbasis transaksi lebih dominan dibanding atribut demografis. Penelitian selanjutnya disarankan untuk menggunakan data yang lebih representatif dan memperkaya fitur perilaku untuk meningkatkan daya prediksi, serta mengevaluasi pendekatan lain yang lebih adaptif terhadap pola data yang lemah.

5.1 Saran Pengembangan Penelitian

Penelitian selanjutnya diharapkan dapat memperluas cakupan dimensi data dengan mengintegrasikan fitur perilaku pelanggan secara *real-time*, seperti data *clickstream*, durasi sesi aplikasi, dan detail log keluhan pelanggan untuk meningkatkan sensitivitas model terhadap perubahan perilaku. Selain itu, disarankan untuk melakukan studi komparatif menggunakan algoritma *ensemble learning* berbasis *boosting*, seperti XGBoost atau LightGBM, guna mengevaluasi potensi peningkatan performa model pada dataset yang memiliki tingkat gangguan (*noise*) tinggi atau pola data yang lebih kompleks dibandingkan algoritma Random Forest.

5.2 Saran Bagi Industri Retail Online

Perusahaan retail online disarankan untuk memprioritaskan program retensi pada segmen pelanggan dengan kontribusi pendapatan tinggi (*high-value*) yang teridentifikasi melalui fitur *Total Spend* dan *Annual Income*, serta melakukan validasi berkelanjutan terhadap integritas data transaksi sebagai input utama model prediksi. Mengingat adanya risiko kesalahan prediksi (*False Positive*), perusahaan sebaiknya menerapkan strategi intervensi yang bersifat persuasif atau non-moneter, seperti layanan personalisasi dan buletin informasi, untuk menjaga efisiensi biaya operasional sambil tetap meminimalisasi potensi perpindahan pelanggan (*churn*).

6. DAFTAR PUSTAKA

- Ahmad, A.K., Jafar, A. and Aljoumaa, K., 2019. Customer churn prediction in telecom using machine learning in big data platform. *Journal of Big Data*, 6(1). <https://doi.org/10.1186/s40537-019-0191-6>.
- Ahn, J., Hwang, J., Kim, D.-Y., Choi, H. and Kang, S.-J., 2020. A Survey on Churn Analysis in Various Business Domains. *Ieee Access*, 8, pp.220816–220839. <https://doi.org/10.1109/access.2020.3042657>.
- Ambildhuke, G.M., Rekha, G. and Tyagi, A.K., 2021. Performance Analysis of Undersampling Approaches for Solving Customer Churn Prediction. pp.341–347. https://doi.org/10.1007/978-981-15-9689-6_37.
- Breiman, L., 2001. Random Forests. *Machine Learning*, [online] 45(1), pp.5–32. <https://doi.org/10.1023/A:1010933404324>.
- Chang, V., Hall, K., Xu, Q., Amao, F., Ganatra, M.A. and Benson, V., 2024. Prediction of Customer Churn Behavior in the Telecommunication Industry Using Machine Learning Models. *Algorithms*, 17(6), p.231. <https://doi.org/10.3390/a17060231>.
- Deng, E., 2024. Customer Churn Prediction Based on Multiple Linear Regression and Random Forest. *Applied and Computational Engineering*, 112(1), pp.22–28. <https://doi.org/10.54254/2755-2721/112/20251786>.
- Ehsani, F. and Hosseini, M., 2024. Customer Churn Analysis Using Feature Optimization Methods and Tree-Based Classifiers. *Journal of Services Marketing*, 39(1), pp.20–35. <https://doi.org/10.1108/jsm-04-2024-0156>.
- English, N., Anesetti-Rothermel, A., Chang, Z., Latterner, A., Benson, A.F., Herman, P., Emery, S., Schneider, J., Rose, S.W., Patel, M. and Schillo, B., 2021. Image Processing for Public Health Surveillance of Tobacco Point-of-Sale Advertising: Machine Learning–Based Methodology. *Journal of Medical Internet Research*, 23(8), p.e24408. <https://doi.org/10.2196/24408>.
- Faris, H., 2018. A Hybrid Swarm Intelligent Neural Network Model for Customer Churn Prediction and Identifying the Influencing Factors. *Information*, 9(11), p.288. <https://doi.org/10.3390/info9110288>.
- Geiler, L., Affeldt, S. and Nadif, M., 2022. A Survey on Machine Learning Methods for Churn Prediction. *International Journal of Data Science and Analytics*, 14(3), pp.217–242. <https://doi.org/10.1007/s41060-022-00312-5>.
- Guliyev, H. and Tatoğlu, F.Y., 2021. Customer Churn Analysis in Banking Sector: Evidence From Explainable Machine Learning Models. *Journal of Applied Microeconometrics*, 1(2), pp.85–99. <https://doi.org/10.53753/jame.1.2.03>.
- Huang, Y., Zhu, F., Yuan, M., Deng, K., Li, Y., Ni, B., Dai, W., Yang, Q. and Zeng, J., 2015. Telco Churn Prediction with Big Data. In: *Proceedings of the 2015 ACM SIGMOD International Conference on Management of Data*. [online] New York, NY, USA: ACM. pp.607–618. <https://doi.org/10.1145/2723372.2742794>.
- Jain, H., Khunteta, A. and Srivastava, S., 2020. Churn Prediction in Telecommunication Using Logistic Regression and Logit Boost. *Procedia Computer Science*, 167, pp.101–112. <https://doi.org/10.1016/j.procs.2020.03.187>.
- Laudon, K.C. and Traver, C. Guercio., 2019. *E-commerce 2019 : business. technology. society*. Pearson.
- Lutfi, A., Alrawad, M., Alsyoud, A., Almaiah, M.A., Al-Khasawneh, A., Al-Khasawneh, A.L., Alshira'h, A.F., Alshirah, M.H., Saad, M. and Ibrahim, N., 2023. Drivers and impact of big data analytic adoption in the retail industry: A quantitative investigation applying structural equation modeling. *Journal of Retailing and Consumer Services*, 70. <https://doi.org/10.1016/j.jretconser.2022.103129>.
- Matuszelański, K. and Kopczewska, K., 2022. Customer Churn in Retail E-Commerce Business: Spatial and Machine Learning Approach. *Journal of Theoretical and Applied Electronic Commerce Research*, 17(1), pp.165–198.

- <https://doi.org/10.3390/jtaer17010009>.
- Rachid, A.D., Amine, A., Bouikhalene, B. and Lbibb, R., 2018. Clustering Prediction Techniques in Defining and Predicting Customers Defection: The Case of E-Commerce Context. *International Journal of Electrical and Computer Engineering (Ijece)*, 8(4), p.2367. <https://doi.org/10.11591/ijece.v8i4.pp2367-2383>.
- Raji, M.A., Olodo, H.B., Oke, T.T., Addy, W.A., Ofodile, O.C. and Oyewole, A.T., 2024. Real-Time Data Analytics in Retail: A Review of USA and Global Practices. *GSC Advanced Research and Reviews*, 18(3), pp.059–065. <https://doi.org/10.30574/gscarr.2024.18.3.0089>.
- Rekha, G., Tyagi, A.K. and Reddy, V.K., 2019. Solving Class Imbalance Problem Using Bagging, Boosting Techniques, With and Without Using Noise Filtering Method. *International Journal of Hybrid Intelligent Systems*, 15(2), pp.67–76. <https://doi.org/10.3233/his-190261>.
- Sam, G., Asuquo, P. and Stephen, B., 2024. Customer Churn Prediction Using Machine Learning Models. *Journal of Engineering Research and Reports*, 26(2), pp.181–193. <https://doi.org/10.9734/jerr/2024/v26i21081>.
- Sapara, N.J. and Patel, H., 2024. Consumer Behavior Analysis Through Advanced-Data Techniques: A Review for Utilities in Retail Marketing. *Interantional Journal of Scientific Research in Engineering and Management*, 08(10), pp.1–5. <https://doi.org/10.55041/ijsrem37895>.
- Sholeh, M., Lestari, U. and Andayati, D., 2025. Hyperparameter Optimization Using Grid Search and Random Search to Improve the Performance of Prediction Models with Decision Trees. *Jurnal Riset Multidisiplin dan Inovasi Teknologi*, 3(03), pp.453–464. <https://doi.org/10.59653/jimat.v3i03.2025>.
- Shu-li, W.U., Yau, W., Ong, T.S. and Chong, S.-C., 2021. Integrated Churn Prediction and Customer Segmentation Framework for Telco Business. *Ieee Access*, 9, pp.62118–62136. <https://doi.org/10.1109/access.2021.3073776>.
- Suh, Y., 2023. Machine learning based customer churn prediction in home appliance rental business. *Journal of Big Data*, 10(1). <https://doi.org/10.1186/s40537-023-00721-8>.
- Sweidan, D., Johansson, U., Gidenstam, A. and Alenljung, B., 2022. Predicting Customer Churn in Retailing. pp.635–640. <https://doi.org/10.1109/icmla55696.2022.00105>.
- Tran, H.D., Le, N. and Nguyen, V.-H., 2023. Customer Churn Prediction in the Banking Sector Using Machine Learning-Based Classification Models. *Interdisciplinary Journal of Information Knowledge and Management*, 18, pp.087–105. <https://doi.org/10.28945/5086>.
- Wen, Z., 2023. Feature Analysis and Model Comparison of Logistic Regression and Decision Tree for Customer Churn Prediction. *Applied and Computational Engineering*, 20(1), pp.55–61. <https://doi.org/10.54254/2755-2721/20/20231073>.
- Wilson, G., Brown, W.L. and Johnson, O., 2024. Technological Innovations and Their Effect on Retail Marketing Effectiveness. <https://doi.org/10.20944/preprints202407.1154.v1>.
- Xu, T., Ma, Y. and Kim, K., 2021. Telecom Churn Prediction System Based on Ensemble Learning Using Feature Grouping. *Applied Sciences*, 11(11), p.4742. <https://doi.org/10.3390/app11114742>.